

线性回归

- 线性模型试图学得一个通过**特征的线性组合**来进行预测的函数，即 $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$
由于 \mathbf{w} 直观表达了**各特征在预测中的重要性**，因此线性模型有很好的可解释性

- **模型假设**： $Y = X\beta + \varepsilon$

- 自变量 X 与因变量 Y 是线性关系
- 误差项 ε 独立同分布，服从 $N(0, \sigma^2)$ 且独立于 X
- 自变量间不存在完全共线性

- **最大似然估计**：根据模型假设 $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ ，似然函数可表示为

$$L(\beta) = \prod_{i=1}^n \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{\varepsilon_i^2}{2\sigma^2}} = \prod_{i=1}^n \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(Y^{(i)} - X^{(i)}\beta)^2}{2\sigma^2}} = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{\sum_{i=1}^n (Y^{(i)} - X^{(i)}\beta)^2}{2\sigma^2}}$$

$$\text{那么 } \hat{\beta} = \arg \max_{\beta} L(\beta) = \hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (Y^{(i)} - X^{(i)}\beta)^2$$

- **最小二乘法**：试图找到一条直线或一个超平面，使所有样本到直线或平面上的欧式距离最小，即 $\hat{\beta} = \arg \min_{\beta} (Y - X\beta)^T (Y - X\beta) = (X^T X)^{-1} X^T Y$

矩阵的逆不存在时的解决方法：（1）减少特征个数（2）正则化

- **梯度下降法**：沿着损失函数梯度下降的方向对参数进行调整直到收敛，即重复以下步骤直

到收敛： $\beta_{j+1} := \beta_j - \alpha \frac{\partial J(\beta)}{\partial \beta_j}$ ，其中

- α 是学习率（Learning Rate），用来控制下降每步的距离（太小会收敛很慢，太大则会跳过最优点）
- $J(\cdot)$ 是损失函数（Loss Function），用来衡量模型的预测精度

- 更一般地，考虑单调可微函数 $g(\cdot)$ ，令 $y = g^{-1}(\mathbf{w}^T \mathbf{x} + b)$ 得到“广义线性模型”（Generalized Linear Model），其中函数 $g(\cdot)$ 称为“联系函数”（Link Function）

- **优点**：线性模型简单直观，可解释性强；可通过正则化来防止过拟合

缺点：处理非线性关系数据时不够灵活，拟合效果较差；模型拟合容易受到异常值或离群点的影响，需要进行预处理；模型假设较为严格